


LangGraph 查询助手与政策 RAG

项目说明 · 核心设计与验证结果

文档整理：2026-09-14；内容依据当前代码与已有验收记录。本文展示现有系统，不展开开发过程。

一个面向政策问答与结构化价格查询的只读 Agent。用户用自然语言提出问题，系统完成意图识别、必要澄清、条件收集、工具执行与证据展示；中断后可以继续，同一请求可以安全重放。

1 系统架构与职责边界



图示为当前限定发布的 catalog_v2 装配。离线流水线负责政策采集、OCR、切分和 Milvus 写入；独立价格采集项目负责 MySQL 数据，在线 Agent 均只读消费。Eval 从公开 HTTP 或组件文件契约独立评分。

用户能力	当前表现
政策查询	检索政策材料，判断证据是否足够，返回带来源引用的回答或有依据的拒答。
商品价格	设备按型号与规格筛选；已有生鲜按品名、地区及批零口径查询。支持补槽、候选选择和价格证据卡片。
多轮交互	保留服务器会话状态，支持冲突确认、刷新恢复、JSON/SSE 与原消息重放。
物流查询	轨迹、资费、时限作为接口遗留保留；正式入口正常提示不可用，不加载演示假数据。

核心取舍

模型负责语义补充，确定性代码负责执行与事实。LangGraph 管理条件边、暂停恢复和 checkpoint；业务规则留在 Domain / Service / Policy，HTTP、数据库与供应商协议留在 Adapter。

技术栈：Python / FastAPI / Pydantic / LangGraph，Vue / TypeScript，Milvus / MySQL / SQLite，DeepSeek，OpenTelemetry / Prometheus / Tempo / Grafana。

2 意图理解与确定性路由

Query Understanding 将自然语言转换成可校验的业务描述，而不是直接产生工具调用。当前商品 profile 用 product_price 统一设备与生鲜；政策和三类物流仍各有类型化意图。一次工作流处理一个明确目标，多意图先澄清。

理解链路：规则优先，模型按需补充

控制 / 显式入口 / 当前会话 → 规则提取 → 必要时模型 fallback → Schema 校验与硬实体重提 → 条件合并。取消、重启等控制行为不交给模型。规则已能决定时不调用模型，模型失败则保留规则能力。

Understanding 字段组	设计作用
schema_version	固定理解合同版本，便于规则、模型、工作流与独立 Eval 对齐。
selected_intent / candidates multi_intent	保留选择、候选及歧义；score 是启发式信号，不当作校准概率或执行许可。
slots / slot_provenance	按意图保存结构化条件及来源。商品条件以 kind 区分 device、fresh、unknown。
missing_slots / ambiguities	显式描述缺字段与冲突，决定继续收集、澄清或结束。
control / source parser_version / prompt_version	区分控制动作、理解来源与解析版本，使结果可以追踪和复验。

模型的输出不是可信业务事实

模型只补充语义分类，Prompt 要求不提供硬槽位。即使输出格式合法，邮件号、重量、地区、商品型号和规格仍从原始输入重新提取。模型不能给出 SQL、任意工具名、数据库 ID、候选 token 或价格。

输入示例	系统处理
“苹果多少钱”	先澄清设备还是水果，不直接猜商品或执行价格查询。
“苹果一斤多少钱”	识别为生鲜价格；按需补地区与批发/零售口径，不因重量误路由运费。
“iPhone 17 256GB 价格”	识别设备和容量条件；匹配到多条事实时交由候选循环，不由模型任选。
“从上海寄到北京 2 公斤多少钱”	识别资费需求；正式能力未装配时即提示不可用，不继续索取无用条件。


Routing：先检查能否执行，再构造 Command

纯 WorkflowPolicy 按控制与预算、意图歧义、能力装配、槽位冲突及领域前置条件决定下一动作。静态 Registry 限定可用 Tool；Descriptor 声明输入、结果、超时和尝试预算，Executor 再校验 Command 与 Tool 是否匹配。

条件按字段原子合并，已确认值不被静默覆盖。改商品、类目或地区需要确认，同时清理不再适用的规格、市场或候选，避免“旧身份 + 新条件”的混合请求。

3 有状态工作流与可靠执行

Stateful Workflow 不是把聊天历史反复拼进 Prompt。服务端保存结构化状态，LangGraph 在可恢复停止点暂停；下一条消息通过 resume 继续，业务策略仍由确定性代码决定。



State、会话元数据与执行收据分开

checkpoint 保存当前意图、槽位、候选、动作、结果/失败及预算；元数据保存 owner 和绝对 TTL；创建、消息、Tool 三层收据保存幂等结果。RAG 是外部知识，不是会话记忆。状态库可能包含用户输入，日志脱敏不等于数据库没有敏感内容。

标识	作用与不变量
conversation / turn	会话定位与一次消息身份；会话 ID 本身不是授权凭证。
query_id	一次逻辑查询可跨多轮补槽和重试；主动新查询生成新 ID，重新读取业务数据。
tool_call_id / 收据	一次逻辑执行的身份；参数指纹只检查一致性，不将相同参数永久缓存。
Idempotency-Key	同键同内容重放原结果；同键不同内容冲突。切换 JSON/SSE 不产生新的业务请求。

有界循环与 Failure Handling

商品查询每个 query 最多 2 次逻辑调用、1 次技术重试、3 轮澄清；补槽、候选选择和刷新不重置额度。图、总 deadline、递归与数据库超时共同约束执行；共享 HTTP 不叠加自动重试。

情况	处理方式
条件不足 / 多候选	进入等待输入；候选澄清是业务步骤，不是故障重试。
无匹配 / 未装配	正常无结果或不可用提示；不编造事实，不换用假工具。
暂时超时 / 429 / 可重试 5xx	按明确白名单和剩余预算退避；不因重放再次获得预算。
错身份 / 错单位 / 合同漂移	拒绝不可信事实，不落成功收据，不以换一种猜法恢复。

恢复语义：同消息重放保留原观察时间；主动再查重新取数。不能承诺跨系统 exactly-once：上游执行成功但本地收据未提交仍有崩溃窗口。

4 统一商品价格：共享核心，不混合语义

设备和生鲜共享只读查询、证据校验与资源生命周期，但不共享一套勉强通用的 SKU 模型。Agent 商品 Tool 与旧 V1 设备接口借用同一 Service；节点不包含价格 SQL，也不按品牌复制业务链路。



边界	设备	已有生鲜
身份	可信的品牌 / 产品 / 规格关联。	来源归一品名、地区和市场；不强制有标准品牌或 SKU。
匹配	先锁定型号与 Pro/Max 等变体，再过滤容量、内存等规格。	约束品名、地域和批零口径；不拿其他地区或另一统计口径替代。
结果	当前配置价、原价类型、在售或无金额状态。	原始报价、标准单位价、来源日及口径，多个来源分别呈现。

候选循环：选择身份，再读最新事实

发现候选 → 返回短期 token → 等待选择 → 校验作用域 → 精确重读同一身份。token 绑定 owner、会话、query、语义条件和期限；期限不超过生成后 10 分钟或会话 TTL。条件变化使候选失效，模型不能自行生成 token。

用户点击后发送独立 price_selection，不把内部 ID 放进消息。最终 SQL 只读取选中 listing / 地区的当前指针；价格可更新，但身份或 revision 已变就要求重新查询，不重新模糊搜索并替换商品。等待用户期间不持有数据库事务。

事实合同：金额、单位、状态和时间成组校验

关键约束	具体行为
当前指针与关联	current 指针、观察、来源版本、地区必须一致；固定 SQL 绑定参数、有界召回、只读一致事务。
金额与单位	使用 Decimal，公开金额为字符串。原始元/500g 与标准元/kg 分开，不跨来源混算。
无金额与旧数据	缺货/下架等状态不是 0 元；旧观察不称实时价。要求“今天”但只有旧来源日时返回 partial。

例如：3.50 元/500g 与 7.000000 元/kg 可同时作为同一事实的两种单位表示，不能误写为 3.50 元/kg。此例为合同示意，不是当前业务报价。

公开 DTO 只保留商品描述、金额/状态、来源、地区和时间，不暴露数据库 ID 或指纹。catalog 查询不自动回退旧表；兼容默认配置的旧代码仍保留。最近有价历史虽有合同，当前 SQL 保守不返回。

5 政策 RAG：先证明证据够用，再生成回答

RAG 是独立、无会话的只读知识服务，通过 HTTP 被 Assistant 复用。它不承担商品查询或 Agent 状态管理。核心判断不是“检索到了相关文档”，而是“这些证据是否足以回答用户的问题”。

数据生产与在线消费分离

offline-pipeline 完成页面/附件采集、解析与 OCR、结构化切分、向量化及 Milvus 写入。稳定 ID、内容摘要和 SQLite 抓取状态支持增量处理；失败附件保留来源关系，不能静默丢弃。在线服务只读索引，不触发抓取、建表或业务数据修复。

共享 contracts 固定 collection、字段和 embedding 约定：m3e-base、768 维、L2 归一化、COSINE。切分后用真实 tokenizer 检查长度，避免静默截断。已有归档批次形成 12,163 个知识片段；这不是实时索引监控。

检索、重排、证据判断与回答



减少无效调用，也保留可解释拒答

没有候选或重排全部拒绝时不调用生成模型；Judge 判断证据不足时不继续生成。系统区分 no_context、reranker_rejected、llm_rejected 与依赖故障，避免把所有失败都解释成“模型不够强”。

例如：知识库可能有寄递损失责任条文，却没有某企业的理赔材料清单。即使召回分数高，也不能据此补出清单；应说明现有资料不足。投诉渠道等有明确依据的问题则返回引用式回答。

边界与复用价值

来源正文按不可信数据处理，上下文有长度上限；引用约束与证据筛选降低无依据回答风险，但不是模型绝不出错的保证。文档有效期、地区适用性和企业资料覆盖仍需治理。独立检索接口不调用 DeepSeek，可供其他业务直接复用。

6 验证结果与运行边界

验收分为组件理解、公开多轮 workflow、真实 SQL、浏览器/部署与真实数据通路，分别记录结果。独立 Eval 不导入业务实现生成标准答案；模型效果、工程回归和线上可用性不能互相替代。

已记录结果	范围与含义
Python 1,900 项通过 Web 114 项通过	2026-09-13 离线回归；另有 52 项 SQL 场景由专用 runner 验证。类型生成、校验及双模式构建通过。
MySQL 5.7 / 8.4 隔离 runner 各 57 项通过	真实执行合成 SQL，验证 V2-only、SELECT-only、旧表不存在/不可访问、关联与单位错误。不是公司库权限审计。
公开 workflow 门禁通过	资费 13 场景 / 28 Turn；商品 7 场景 / 9 Turn。候选 token、重放、恢复与越权另有 API/Web 回归。
CI 全部 4 项任务成功	提交 60eebda：应用/契约/Web、两版 MySQL、合成部署恢复/回退。CI 不自动发布公司服务器。

模型与 RAG 的关键评测记录

评测范围	结果	解释边界
Understanding 48 条合成 development	Rules / Hybrid Macro-F1： 0.7068 / 1.0000； Hybrid 模型调用 20/48。	固定旧设备意图 profile；含已见样本，不是 holdout，也不代表新商品范围泛化。
RAG 归档基线 80 条私有样本 48 可答 / 32 拒答	Recall@5 = 1.0000； MRR@5 = 0.8469； 错误拒答 0/48，错误回答 0/32。	rag-api 0.5.0 的存档结果，不是当前线上准确率。原始私有报告不随仓库分发。

以上为既有固定样本证据，不在生成本文时重新调用模型。RAG 归档串行 P95 为 8.97 秒，另一次 24 条并发样本 P95 为 40.67 秒；两批口径不同，但已提示排队限制，不能宣称生产 SLA。

当前交付与可操作性

单实例内网版本已限定发布。真实 HTTP 已验政策引用回答、iPhone 17 256GB 候选报价、上海黄瓜零售补槽/双单位、旧来源日 partial、原消息重放及跨访客拒绝；最近真实验收为 2026-09-11，不是持续可用率监控。

浏览器通过同源代理访问 API，服务 Key 不进 JS；签名 Cookie 约束匿名 owner。State 4 保留旧完成事实、拒绝不安全的旧 pending；快照 GET 不执行 Graph 或续期。停服整库快照恢复到新目录，回退使用匹配的旧状态副本。

语义 Trace 解释路径，逐 Node OTel 记录实际执行耗时；等待用户不计入节点时长，消息重放不伪造新 span。本地监控栈可看指标并下钻 Trace，但没有生产告警/SLO。

适用边界：当前为单实例、匿名访客和获准内网 HTTP，未提供链路加密或企业 RBAC。完整五品牌语义、生产最小权限、来源时效和目标页面人工交互仍有限；物流真实接口保持遗留。

资料依据

以仓库当前状态、运行设计、价格消费合同、RAG 机制及已记录评测为依据。当前状态 · 评测与验收依据 · 对应提交 CI。本文不包含凭据、内网地址、原始业务数据或开发阶段计划。